

Preprocessing

Wprowadzenie:

1. Celem projektu jest wstępne przetworzenie danych zgodnie z konwencją (data cleaning, data transformation, data reduction) oraz analiza (statystyk, relacji oraz rozkładów).

Teoria:

Rozkład normalny (rozkład Gaussa) - symetryczny rozkład zmiennej losowej, w którym wartości skupiają się wokół średniej, a częstość występowania wartości oddalonych od średniej maleje zgodnie z określoną krzywą dzwonową. **Test Shapiro-Wilka** - test statystyczny służący do sprawdzenia, czy próbka danych pochodzi z rozkładu normalnego. **Korelacja Spearmana** - nieparametryczny współczynnik korelacji, mierzący monotoniczną zależność między dwiema zmiennymi, bez założenia o normalności danych. **Test chi-kwadrat** (test niezależności) - test statystyczny służący do oceny, czy dwie zmienne kategoryczne są od siebie niezależne, poprzez porównanie obserwowanych i oczekiwanych częstości. **Regresja logistyczna** - model statystyczny służący do przewidywania prawdopodobieństwa zajścia zdarzenia (np. przeżycia) na podstawie jednej lub więcej zmiennych niezależnych.

Dane:

Zbiór danych titanic przedstawia informacje o pasażerach statku Titanic.

Survived (1 = pasażer przeżył, 0 = nie przeżył), **Pclass** (1 = 1 klasa, 2 = 2 klasa, 3 = 3 klasa), **Name** (imię i nazwisko), **Sex** (płeć), **Age** (wiek), **SibSp** (liczba rodzeństwa/małżonków na pokładzie), **Parch** (liczba rodziców/dzieci na pokładzie), **Fare** (opłata za bilet), **Embarked** (port zaokrętowania - C = Cherbourg, Q = Queenstown, S = Southampton)

Czyszczenie danych

1. Usunięcie danych nieistotnych

```
# Usunięcie danych nieistotnych
titanic1 = subset(titanic, select = -c(Passenger.Id, Name, Fare, Cabin, Ticket, SibSp, Parch))
names(titanic1)
```

Dane takie jak Passenger.Id, Name, Cabin oraz Ticket to dane nieprzystosowane do żadnej analizy (nie da się obliczyć żadnych zależności) oraz zbędne. Jeżeli chcemy poznać status społeczno-ekonomiczny pasażerów lepszą alternatywą do Fare będzie Pclass, więc nie potrzebujemy obu kolumn. Kategorie SibSp oraz Parch są zbyt ogólne do konkretnej analizy - nie wiemy czy dane odnoszą się do współmałżonków czy rodzeństwa oraz rodziców czy dzieci. Dane, które są konkretne i pozostały w analizie to: Survived, Pclass, Sex, Age oraz Embarked.

2. Niepoprawny zapis

W przypadku danych Survived pojawiają się liczby, które nie pasują do obu opcji. Jako, że błędów jest niewiele, a niektóre opcje nie pasują do żadnych z opcji (np. 112) to błędne zapisy można usunąć.

```
# Znalezienie błędnych danych SURVIVED
table(titanic1$Survived)
titanic1 <- titanic1 %>% filter(Survived %in% c(0,1))
```

-1	0	1	111	112
1	549	338	1	2

Dane na temat płci pasażerów zostały wprowadzone niepoprawnie. Przez literówki można łatwo się domyślić która opcja miała być wpisana, więc dane można poprawić, a nie usunąć.

```
f2emale feemale female mal3e mal4e male malle malwe
1 3 310 1 1 573 1 1
```

```
# SEX
table(titanic1$Sex)
titanic1 <- titanic1 %>%
  mutate(Sex = recode(Sex,
    "f2emale" = "female",
    "feemale" = "female",
    "mal3e" = "male",
    "mal4e" = "male",
    "malle" = "male",
    "malwe" = "male"))
table(titanic1$Sex)
```

```
female male
314 577
```

W przypadku danych Embarked występują problemy z formatowaniem - są zarówno wielkie i małe litery. Dodatkowo dwa pola zostały zostawione puste, jako że stanowią mały procent danych możemy je pominąć.

```

      C      Q      S      S
2 168    77    9 635



# EMBARKED
table(titanic1$Embarked)
titanic1 <- titanic1 %>% mutate(Embarked = toupper(Embarked))
titanic1 <- titanic1 %>% filter(Embarked %in% c("S", "Q", "C"))
table(titanic1$Embarked)

      C      Q      S
168    77    644

```

3. Brak danych

Kategoria Age ma zbyt dużą liczbę niewpisanych danych, aby je pominąć (177). Brakujące wartości zostały zastąpione średnią z wieku, osobno dla kobiet i mężczyzn. Żeby wyniki były bardziej precyzyjne obliczenia zostały przeprowadzone dwa razy: raz z uwzględnieniem outlierów, a raz bez.



Jak widoczne jest na powyższych wykresach, zbiór danych charakteryzuje rozkład prawoskośny (asymetria dodatnia), czyli najstarsi pasażerowie są charakteryzowani jako outlierzy.

Po obliczeniu średnich otrzymujemy wyniki:

```

> print(femaleAge)
[1] 27.8677
> print(maleAge)
[1] 30.69439
> print(femaleAge_no)
[1] 27.8677
> print(maleAge_no)
[1] 29.71743

```

Dla kobiet wynik pozostał ten sam, natomiast różnica dla mężczyzn wynosi ok. 1 rok. Jako, że wartości są zbliżone możemy kontynuować analizę uzupełniając brak wartości średnią bez outlierów.

```

Q1 <- quantile(titanic1$Age, 0.25, na.rm = TRUE)
Q3 <- quantile(titanic1$Age, 0.75, na.rm = TRUE)

IQR <- Q3 - Q1

lower_bound <- Q1 - 1.5 * IQR
upper_bound <- Q3 + 1.5 * IQR

titanic1_n0 <- titanic1 %>% filter(titanic1$Age >= lower_bound & titanic1$Age<= upper_bound)
names(titanic1)

# TITANIC1 Obliczamy średnią wieku osobno dla kobiet i mężczyzn
femaleAge <- mean(titanic1 %>% filter(Sex == "female") %>% pull(Age), na.rm = TRUE)
maleAge <- mean(titanic1 %>% filter(Sex == "male") %>% pull(Age), na.rm = TRUE)

# Zastępujemy brak wartości średnią
titanic1 <- titanic1 %>%
  mutate(Age = ifelse(is.na(Age) & Sex == "male", maleAge,
    ifelse(is.na(Age) & Sex == "female", femaleAge, Age)))

# TITANIC1_NO
femaleAge_n0 <- mean(titanic1_n0 %>% filter(Sex == "female") %>% pull(Age), na.rm = TRUE)
maleAge_n0 <- mean(titanic1_n0 %>% filter(Sex == "male") %>% pull(Age), na.rm = TRUE)

# Zastępujemy brak wartości średnią
titanic1_n0 <- titanic1_n0 %>%
  mutate(Age = ifelse(is.na(Age) & Sex == "male", maleAge,
    ifelse(is.na(Age) & Sex == "female", femaleAge, Age)))

# Porównujemy średnie dla zawartości z outlierami i bez
print(femaleAge)
print(maleAge)
print(femaleAge_n0)
print(maleAge_n0)

```

4. Podsumowanie


Większość kolumn zostało usunięte, ponieważ były nieistotne. Niepoprawny zapis został zmieniony na poprawny, gdy była możliwość domysłu lub usunięty gdy braki były odpowiednio małe. Braki danych zostały uzupełnione średnią.

Statystyki opisowe

Zmienna Age, reprezentująca wiek pasażerów Titanica, jest zmienną ciągłą o rozkładzie prawoskośnym, co oznacza, że większość pasażerów była w młodszym wieku, a mniejsza liczba osób miała znacznie wyższy wiek. Średnia wieku wynosi około 29 lat, a mediana nieco mniej, co potwierdza asymetrię rozkładu. Wariancja wieku wskazuje na stosunkowo dużą zmienność w populacji pasażerów, a odchylenie standardowe (zwykle ok. 14 lat) pokazuje, że wiek większości pasażerów mieścił się w przedziale 15–45 lat. W danych występują również wartości odstające – np. dzieci w wieku poniżej roku oraz osoby powyżej 70 lat.

W przeprowadzonej analizie danych z Titanica zbadano zależności pomiędzy wiekiem (Age), klasą podróży (Pclass) oraz przeżyciem (Survived). Ze względu na brak normalności rozkładów (potwierdzony testem Shapiro-Wilka dla wieku oraz charakter binarny i porządkowy pozostałych zmiennych), zastosowano nieparametryczny test korelacji Spearmana. Analiza wykazała słabą, lecz istotną statystycznie ujemną korelację pomiędzy wiekiem a przeżyciem – starsi pasażerowie mieli nieco mniejsze szanse na przeżycie. Silniejsza ujemna korelacja wystąpiła pomiędzy wiekiem a klasą – pasażerowie podróżujący w wyższej klasie byli zazwyczaj starsi. Najwyraźniejszą zależność odnotowano między

przeżyciem a klasą podróży: osoby z wyższych klas miały istotnie większe szanse na przeżycie. Wyniki te potwierdzają, że status społeczny i wiek wpływały na przeżywalność pasażerów Titanica.



Na podstawie danych można zbadać różnice w wskaźnikach przeżycia pomiędzy płciami oraz klasami podróży, wykorzystując tabele kontyngencji i testy chi-kwadrat. Analizę rozkładu wieku pasażerów można wykonać za pomocą statystyk opisowych oraz wizualizacji, takich jak histogramy i wykresy pudełkowe, a także porównać wiek pasażerów w różnych klasach lub wśród osób, które przeżyły i tych, które zginęły. Dodatkowo, zmienna Embarked umożliwia analizę różnic w strukturze pasażerów w zależności od portu zaokrętowania oraz ich powiązania z przeżywalnością lub klasą.